

Comparación de Modelos de Regresión

OLS versus LASSO

Tópicos de Estadística Avanzada · Departamento de Matemática · UNS

Material teórico de clase · Concentración de cobre como hilo conductor

Introducción

Uno de los problemas centrales en estadística aplicada es el de la **comparación de modelos**: dado un conjunto de datos y dos o más modelos candidatos, ¿cuál preferimos y por qué? Esta pregunta parece sencilla pero esconde una tensión fundamental que atraviesa todo el material de esta clase.

A lo largo del documento usamos un ejemplo concreto: la predicción de la **ley de cobre** (concentración en %) a partir de variables geoquímicas medidas en muestras de roca, provenientes de la base de datos pública del USGS (U.S. Geological Survey — Servicio Geológico de los Estados Unidos). Este contexto es natural para ilustrar los métodos porque los datos geoquímicos presentan exactamente las características que hacen interesante la comparación: muchas variables correlacionadas entre sí y una señal que no siempre es fácil de aislar.

1. Motivación: ¿qué significa “mejor modelo”?

1.1 El dilema sesgo-varianza

Antes de hablar de errores, precisamos qué entendemos por **modelo**. En este documento, un modelo es una función $\hat{f}(\mathbf{x})$ que, dado un vector de predictores $\mathbf{x}$ (composición geoquímica de una muestra), produce una predicción de la respuesta y (ley de cobre). Esa función se construye a partir de los datos de entrenamiento: OLS y LASSO son dos formas distintas de construirla, con distintos criterios de ajuste.

Todo modelo estadístico comete dos tipos de error: **sesgo** y **varianza**. El sesgo mide qué tan lejos está, en promedio, la predicción del modelo de la respuesta verdadera. La varianza mide cuánto cambia esa predicción cuando entrenamos el modelo con distintas muestras del mismo proceso.

En criollo: un modelo con alto sesgo es el que sistemáticamente se equivoca en la misma dirección sin importar los datos —como una regla que siempre subestima la ley de cobre en zonas de alta mineralización. Un modelo con alta varianza *aprende de memoria* los datos de entrenamiento: ajusta tan bien a los datos disponibles que captura el ruido específico de esa muestra, y cuando llegan datos nuevos con ruido diferente, falla. Esto se llama *sobreajuste* u *overfitting*.

La tensión entre ambos es inevitable: reducir el sesgo generalmente implica aumentar la complejidad del modelo (más variables, más parámetros libres), lo que aumenta la varianza. Y viceversa: simplificar el modelo reduce la varianza pero introduce sesgo. No hay forma de minimizar ambos al mismo tiempo. El objetivo es encontrar el balance óptimo.

Ejemplo: concentración de cobre (USGS)

Un modelo OLS con las 40 variables geoquímicas disponibles puede ajustarse perfectamente a las muestras de entrenamiento y predecir muy mal la ley de cobre en pozos nuevos: alta varianza, bajo sesgo aparente. Un modelo LASSO que selecciona solo 6 variables introduce algo de sesgo pero predice mucho mejor fuera de muestra.

El error de predicción esperado puede descomponerse en tres términos:

$$\text{EPE} = \text{Sesgo}^2 + \text{Varianza} + \text{Ruido irreducible}$$

El ruido irreducible es la variabilidad intrínseca del proceso que ningún modelo puede capturar. El objetivo es minimizar la suma $\text{Sesgo}^2 + \text{Varianza}$, no cada término por separado.

¿Por qué el sesgo aparece al cuadrado? Al descomponer el error cuadrático medio esperado $\mathbb{E}[(y - \hat{f}(\mathbf{x}))^2]$, el término cruzado entre el sesgo y la varianza tiene esperanza cero (el sesgo es una constante respecto a la variabilidad de $\hat{f}$). Lo que queda es $(\mathbb{E}[\hat{f}] - f)^2$ —el sesgo al cuadrado— más $\mathbb{E}[(\hat{f} - \mathbb{E}[\hat{f}])^2]$ —la varianza. La elevación al cuadrado garantiza además que el sesgo contribuye siempre positivamente al error, independientemente de su signo.

Cuando comparamos modelos, la pregunta “¿cuál es mejor?” no tiene una sola respuesta: depende de *para qué* lo queremos usar. Esta sección desglosa las dos dimensiones clave de esa pregunta.

1.2 ¿Mejor para describir o para predecir?

Podemos hacernos dos preguntas muy diferentes. La primera: *¿cuál modelo describe mejor los datos que ya tenemos?* La segunda: *¿cuál modelo predice mejor datos nuevos que aún no vimos?* Estas preguntas tienen respuestas distintas y requieren herramientas distintas.

El R^2 , tal como se calcula habitualmente, responde a la primera pregunta: siempre mejora o se mantiene igual cuando agregamos variables, aunque esas variables sean ruido puro. Esto lo convierte en una métrica engañosa para comparar modelos de distinta complejidad.

Por qué el R^2 no alcanza

Agregar la variable “número de característica del papel del informe” a un modelo geoquímico nunca puede bajar el R^2 . El modelo simplemente le asigna un coeficiente cercano a cero. Pero sí consume un grado de libertad y deteriora la predicción fuera de muestra. Por eso necesitamos criterios que penalicen la complejidad.

1.3 ¿Mejor para seleccionar el modelo verdadero o para predecir?

Esta distinción es más sutil pero conceptualmente importante. Existen dos filosofías de comparación de modelos:

- **Selección consistente:** queremos identificar el modelo que generó los datos, asumiendo que ese modelo existe y está en nuestra lista de candidatos. El BIC (Criterio de Información Bayesiano) tiene esta propiedad: con suficientes datos, selecciona el modelo verdadero con probabilidad 1. Penaliza más fuertemente la complejidad porque su objetivo es descartar modelos sobreparametrizados.
- **Eficiencia predictiva:** queremos el modelo que minimice el error de predicción esperado, sin asumir que el “modelo verdadero” está entre los candidatos. El AIC (Criterio de Información

de Akaike) apunta a este objetivo: tolera algo de complejidad adicional si eso reduce el error de predicción.

La diferencia práctica es importante: con muestras grandes, BIC tiende a elegir modelos más chicos que AIC. Con muestras pequeñas, ambos pueden coincidir. En la práctica geológica, los procesos son tan complejos que ningún modelo lineal es “el verdadero”: la perspectiva de eficiencia predictiva suele ser más honesta. Retomaremos esta distinción con detalle en la Sección 4.1.

1.4 Los dos modelos que vamos a comparar

En esta clase nos concentramos en comparar dos modelos de regresión lineal: **OLS** (Mínimos Cuadrados Ordinarios) y **LASSO**. Ambos modelan la ley de cobre como combinación lineal de las variables geoquímicas, pero difieren en cómo estiman los coeficientes. OLS minimiza el error de ajuste sin restricciones; LASSO agrega una penalización que fuerza a algunos coeficientes a ser exactamente cero, combinando ajuste con selección automática de variables.

Sean $\mathbf{y} \in \mathbb{R}^n$ el vector de respuestas (ley de cobre) y $\mathbf{X} \in \mathbb{R}^{n \times p}$ la matriz de diseño con los predictores geoquímicos (SiO_2 , Al_2O_3 , Fe_2O_3 , MgO , CaO , Na_2O , K_2O , Mo, Pb, Zn, pH, profundidad, entre otros).

OLS minimiza la suma de cuadrados de residuos sin restricciones:

$$\hat{\boldsymbol{\beta}}_{\text{OLS}} = \arg \min_{\boldsymbol{\beta}} \|\mathbf{y} - \mathbf{X}\boldsymbol{\beta}\|^2$$

LASSO (Least Absolute Shrinkage and Selection Operator — Operador de Contracción y Selección por Valor Absoluto Mínimo) agrega una penalización sobre la norma L_1 de los coeficientes:

$$\hat{\boldsymbol{\beta}}_{\text{LASSO}} = \arg \min_{\boldsymbol{\beta}} \|\mathbf{y} - \mathbf{X}\boldsymbol{\beta}\|^2 + \lambda \|\boldsymbol{\beta}\|_1$$

donde $\lambda \geq 0$ es el parámetro de regularización y $\|\boldsymbol{\beta}\|_1 = \sum_j |\beta_j|$ es la norma L_1 del vector de coeficientes [4].

2. OLS como punto de referencia

2.1 Supuestos del modelo lineal clásico

OLS descansa sobre un conjunto de supuestos que, cuando se cumplen, garantizan propiedades muy deseables. Presentamos cada uno con su interpretación práctica en el contexto geoquímico.

S1. Linealidad

La respuesta es una función lineal de los predictores: $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$. En criollo: el efecto de cada variable sobre la ley de cobre es constante, sin importar el valor de las demás. Este supuesto es una aproximación; en geoquímica las interacciones entre elementos pueden ser importantes.

S2. Exogeneidad estricta: $\mathbb{E}[\boldsymbol{\varepsilon} \mid \mathbf{X}] = \mathbf{0}$

Los errores tienen esperanza cero dado cualquier valor de los predictores. Implica que no hay variables omitidas correlacionadas con las incluidas. Si dejamos afuera la profundidad de la muestra y esta correlaciona con la composición química, violamos este supuesto.

S3. Homocedasticidad: $\text{Var}(\boldsymbol{\epsilon} \mid \mathbf{X}) = \sigma^2 \mathbf{I}$

La varianza del error es constante. En datos de perforación, las muestras superficiales suelen tener mayor variabilidad que las profundas (o viceversa), lo que viola este supuesto y requiere corrección.

S4. No multicolinealidad perfecta: $\text{rango}(\mathbf{X}) = p$

Ninguna variable predictora es combinación lineal exacta de las demás. Este es el supuesto más frecuentemente comprometido en datos geoquímicos: SiO_2 , Al_2O_3 y Na_2O suelen estar altamente correlacionados porque derivan del mismo proceso de alteración hidrotermal. La multicolinealidad no impide estimar $\boldsymbol{\beta}$ pero infla dramáticamente la varianza de los estimadores, haciendo que el modelo sea inestable.

Multicolinealidad en datos geoquímicos

Con 20 o más óxidos medidos sobre las mismas muestras, las correlaciones entre predictores son inevitables. Un cambio pequeño en los datos de entrenamiento puede producir coeficientes radicalmente distintos. LASSO mitiga este problema al forzar a que algunos coeficientes sean exactamente cero.

2.2 Propiedades de los estimadores OLS

Bajo los supuestos S1–S4, el estimador OLS satisface el **Teorema de Gauss-Markov**: es el estimador lineal insesgado de mínima varianza (BLUE — Best Linear Unbiased Estimator). La demostración puede consultarse en Hayashi (2000, cap. 1) o Greene (2012, cap. 2).

Las propiedades clave son:

- Insesgado: $\mathbb{E}[\hat{\boldsymbol{\beta}}_{\text{OLS}}] = \boldsymbol{\beta}$
- Varianza: $\text{Var}(\hat{\boldsymbol{\beta}}_{\text{OLS}}) = \sigma^2(\mathbf{X}'\mathbf{X})^{-1}$
- Consistente: $\hat{\boldsymbol{\beta}}_{\text{OLS}} \xrightarrow{p} \boldsymbol{\beta}$ cuando $n \rightarrow \infty$

Cuando la multicolinealidad es severa, $(\mathbf{X}'\mathbf{X})^{-1}$ tiene valores propios muy grandes, lo que infla la varianza. El estimador sigue siendo insesgado pero prácticamente inutilizable: los coeficientes pueden tener signos incorrectos y cambiar dramáticamente entre muestras.

3. LASSO: de la penalización a la selección

LASSO aborda directamente los dos problemas que tiene OLS en presencia de muchas variables correlacionadas: la inestabilidad de los coeficientes y la falta de selección automática. La idea central es simple: agregar un *costo* por usar variables. Cada coeficiente no nulo tiene un precio proporcional a su valor absoluto. El modelo entonces equilibra reducir el error de ajuste con reducir ese costo, lo que lleva naturalmente a descartar las variables menos útiles fijando sus coeficientes en cero.

¿Por qué esto mejora el problema de multicolinealidad? Cuando dos variables están muy correlacionadas —como SiO_2 y Al_2O_3 en datos de alteración hidrotermal— OLS no puede distinguir cuánto del efecto corresponde a cada una y produce coeficientes inestables con varianzas enormes. LASSO, en cambio, tiende a elegir una de las dos y llevar la otra a cero, produciendo una solución más estable aunque algo sesgada. El trade-off sesgo-varianza vuelve a aparecer, pero ahora lo controlamos explícitamente mediante λ .

3.1 Intuición geométrica: L_1 versus L_2

La clave para entender por qué LASSO produce coeficientes exactamente nulos —y Ridge no— está en la geometría de las restricciones.

Minimizar $\|\mathbf{y} - \mathbf{X}\boldsymbol{\beta}\|^2$ sujeto a $\|\boldsymbol{\beta}\|_1 \leq t$ (formulación equivalente a LASSO) equivale a encontrar el punto donde la elipse de nivel del RSS toca por primera vez la bola L_1 . La bola L_1 tiene **vértices** en los ejes coordenados. En esos vértices, algunos coeficientes son exactamente cero. La bola L_2 (Ridge) es redonda: no tiene vértices, y el punto de contacto rara vez cae exactamente sobre un eje.

Fig. 1: Comparison of L1 (LASSO) vs. L2 (Ridge) Balls and Contact Points with RSS Contours in $\mathbb{R}^2$




Figure 1: Geometría de las penalizaciones L_1 y L_2 . En dimensión alta, los vértices de la bola L_1 se multiplican y la propiedad de selección de variables se vuelve aún más pronunciada.

3.2 El rol del parámetro λ

λ controla el trade-off entre ajuste y parsimonia:

- $\lambda = 0$: recuperamos OLS. Todos los coeficientes son libres.
- $\lambda \rightarrow \infty$: todos los coeficientes se contraen a cero. Modelo nulo.
- λ óptimo: un subconjunto de coeficientes es exactamente cero (selección de variables) y los restantes están contraídos hacia cero (reducción de varianza).

En el ejemplo de cobre: con $\lambda = 0$ LASSO usa los 40 predictores. Con λ óptimo puede seleccionar solo Mo, Fe_2O_3 , K_2O , profundidad y tipo litológico, que son los verdaderos indicadores de mineralización cuprífera.

3.3 Grados de libertad efectivos

Los **grados de libertad** de un modelo cuantifican cuánta información de los datos consume el proceso de ajuste. Intuitivamente, cada parámetro libre que se estima “usa” un grado de libertad: reduce en uno los grados disponibles para estimar la varianza del error. En términos más formales, los grados de libertad miden la sensibilidad de los valores ajustados $\hat{\mathbf{y}}$ ante perturbaciones en $\mathbf{y}$: $\text{df} = \sum_i \partial \hat{y}_i / \partial y_i$.

En OLS, los valores ajustados son $\hat{\mathbf{y}} = \mathbf{H}\mathbf{y}$ donde $\hat{\mathbf{H}} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'$ es la matriz sombrero. Entonces $\partial \hat{y}_i / \partial y_i = H_{ii}$ y los grados de libertad son $\text{tr}(\mathbf{H}) = p$: exactamente el número de predictores. Cada predictor contribuye con exactamente un grado de libertad porque los coeficientes se estiman de forma irrestricta.

En LASSO esto no es tan directo porque la penalización modifica la estructura del estimador y los coeficientes no son funciones lineales de $\mathbf{y}$. Zou, Hastie y Tibshirani [5] demostraron, usando el marco SURE (Stein's Unbiased Risk Estimator — Estimador de Riesgo Insesgado de Stein), que el número de coeficientes no nulos en la solución LASSO es un estimador insesgado de los grados de libertad efectivos:

$$\text{df}(\lambda) = \left| \{j : \hat{\beta}_j(\lambda) \neq 0\} \right|$$

Este resultado es notable: no requiere supuestos sobre $\mathbf{X}$ y es computacionalmente trivial. Permite calcular AIC y BIC para LASSO con la misma fórmula que para OLS, simplemente reemplazando p por $\text{df}(\lambda)$.

3.4 Estandarización: un paso obligatorio

Antes de aplicar LASSO, todas las variables predictoras deben estandarizarse (media cero, desvío estándar uno). La razón es que la penalización L_1 trata a todos los coeficientes por igual: una variable medida en ppm y otra en % tendrán coeficientes de órdenes de magnitud distintos, y la penalización los afectaría de forma inequitativa.

Estandarización en datos geoquímicos

En datos del USGS, las variables están en unidades muy distintas: SiO_2 puede estar en porcentaje (30–70%), mientras que Mo aparece en ppm (0,1–500). Sin estandarización, LASSO descartaría Mo sistemáticamente por tener coeficientes pequeños en escala absoluta, aunque sea un predictor clave de mineralización cuprífera.

3.5 Selección de λ por validación cruzada

El valor de λ se elige por validación cruzada K -fold (ver Sección 4.2): se prueban múltiples valores de λ en una grilla logarítmica, se evalúa el MSE de predicción fuera de muestra para cada uno, y se selecciona el λ que lo minimiza. Una alternativa conservadora es λ_{ISE} : el mayor λ cuyo MSE está dentro de un error estándar del mínimo, favoreciendo modelos más parsimoniosos.

3.6 Elastic Net: combinando L_1 y L_2

El Elastic Net (Red Elástica) es una extensión natural de LASSO que combina penalizaciones L_1 y L_2 :

$$\hat{\boldsymbol{\beta}}_{\text{EN}} = \arg \min_{\boldsymbol{\beta}} \|\mathbf{y} - \mathbf{X}\boldsymbol{\beta}\|^2 + \lambda \left[\alpha \|\boldsymbol{\beta}\|_1 + (1 - \alpha) \|\boldsymbol{\beta}\|_2^2 \right]$$

donde $\alpha \in [0, 1]$ controla el balance entre L_1 y L_2 . Con $\alpha = 1$ recuperamos LASSO; con $\alpha = 0$ recuperamos Ridge. El Elastic Net resuelve dos limitaciones de LASSO: (a) cuando $p > n$, LASSO selecciona como máximo n variables; (b) cuando hay grupos de variables altamente correlacionadas, LASSO tiende a elegir una arbitrariamente mientras que Elastic Net puede seleccionar el grupo completo.

Óxidos de origen común en sistemas de alteración hidrotermal

En depósitos de cobre de tipo pórfido, la alteración potásica produce simultáneamente enriquecimiento en K_2O y Al_2O_3 (por formación de biotita y feldespato potásico) y empobrecimiento en Na_2O y CaO (destrucción de plagioclasa). Estas cuatro variables se mueven juntas por el

mismo proceso geoquímico, generando correlaciones muy altas entre sí. LASSO elegiría una y descartaría las demás, perdiendo señal. Elastic Net las retiene todas con coeficientes moderados, aprovechando la información combinada del ensamble de alteración.

4. Las tres herramientas de comparación

Cada herramienta de comparación que vamos a ver tiene una filosofía distinta y responde a una pregunta diferente. Antes de entrar en los detalles técnicos, vale la pena tener clara esa filosofía para saber qué estamos buscando en cada caso.

Los **criterios de información** (AIC, BIC) parten de la teoría de la información: penalizan la complejidad de forma analítica y permiten comparar modelos sin necesidad de datos adicionales. Su limitación es que dependen de supuestos distribucionales y de que los grados de libertad efectivos estén bien calculados.

La **validación cruzada** es empírica y agnóstica respecto al modelo: simplemente mide el error de predicción real en datos que el modelo no vio. Es la herramienta más directa para evaluar capacidad predictiva, pero no produce un p -valor ni cuantifica si la diferencia es “significativa”.

El **bootstrap paramétrico** es inferencial: construye una distribución de referencia bajo el modelo nulo y permite calcular la probabilidad de observar la diferencia encontrada por azar. Es la herramienta más costosa computacionalmente pero la única que provee significancia estadística formal cuando el LRT (Likelihood Ratio Test) clásico no aplica.

Las tres son complementarias. En la práctica, usarlas en conjunto es más robusto que depender de cualquiera por separado.

4.1 Criterios de información: AIC y BIC

4.1.1 Derivación del AIC desde la divergencia de Kullback-Leibler

El AIC (Criterio de Información de Akaike — Akaike Information Criterion) nace de una pregunta precisa: ¿cuán lejos está el modelo ajustado de la distribución verdadera que generó los datos? La herramienta para medir esta distancia es la **divergencia de Kullback-Leibler** (KL):

$$D_{\text{KL}}(g \parallel f_{\theta}) = \int g(x) \log \frac{g(x)}{f(x|\theta)} dx$$

donde g es la distribución verdadera (desconocida) y $f(\cdot|\theta)$ es el modelo ajustado. Un valor $D_{\text{KL}} = 0$ significa que el modelo es exactamente correcto; valores mayores indican mayor distancia a la verdad.

Minimizar D_{KL} es equivalente a maximizar $\mathbb{E}_g[\log f(X|\theta)]$, la log-verosimilitud esperada bajo la distribución verdadera. [1] demostró que la log-verosimilitud evaluada en $\hat{\theta}$ (el estimador de máxima verosimilitud) sobreestima este valor en aproximadamente p (el número de parámetros libres). Esta sobreestimación ocurre porque $\hat{\theta}$ fue optimizado sobre los mismos datos con los que se evalúa la log-verosimilitud.

Corrigiendo ese sesgo se obtiene el AIC:

$$\text{AIC} = -2 \ell(\hat{\theta}) + 2p$$

donde $\ell(\hat{\theta})$ es la log-verosimilitud maximizada y p es el número de parámetros. En criollo: AIC

premia el ajuste (primer término) y penaliza la complejidad (segundo término). Entre dos modelos, preferimos el de menor AIC.

4.1.2 El BIC y su lógica bayesiana

El BIC (Criterio de Información Bayesiano — Bayesian Information Criterion) surge de aproximar el logaritmo de la probabilidad marginal del modelo (factor de Bayes) para n grande [3]:

$$\text{BIC} = -2\ell(\hat{\theta}) + p \log n$$

La penalización es más severa que en AIC cuando $n > e^2 \approx 7,4$, lo que ocurre en casi cualquier aplicación real. Esto hace que BIC favorezca modelos más parsimoniosos y sea *consistente*: con suficientes datos selecciona el modelo verdadero (si está entre los candidatos). AIC, en cambio, es *eficiente*: minimiza el error de predicción esperado.

4.1.3 ¿Cuándo usar AIC y cuándo BIC?

Criterio	AIC	BIC
Objetivo	Eficiencia predictiva	Selección del modelo verdadero
Penalización	$2p$	$p \log n$
Consistente	No	Sí (si el modelo verdadero está en el conjunto)
Tendencia	Sobreselecciona (modelos más grandes)	Subselecciona (modelos más pequeños)
Recomendado cuando	El objetivo es predecir; el modelo “verdadero” es idealización	Se cree que el modelo verdadero está entre los candidatos

En el contexto del ejemplo de cobre, dado que los modelos geoquímicos son aproximaciones y no existe un modelo lineal “verdadero”, AIC es más apropiado para selección predictiva. BIC puede usarse como criterio de robustez secundario.

4.1.4 AIC y BIC con LASSO: usando los grados de libertad efectivos

Para aplicar AIC y BIC a LASSO, reemplazamos p por $\text{df}(\lambda) = |\text{soporte}(\hat{\beta})|$, el número de coeficientes no nulos [5]:

$$\text{AIC}_{\text{LASSO}} = -2\ell(\hat{\beta}_{\text{LASSO}}) + 2\text{df}(\lambda) \quad \text{BIC}_{\text{LASSO}} = -2\ell(\hat{\beta}_{\text{LASSO}}) + \text{df}(\lambda) \log n$$

Esto permite comparar directamente OLS (con p predictores) y LASSO (con $\text{df}(\lambda)$ predictores efectivos) en la misma escala.

4.2 Validación cruzada K -fold

4.2.1 Definición formal

La validación cruzada K -fold estima el error de predicción fuera de muestra dividiendo los datos en K partes iguales. Sea $\mathcal{I}_k$ el conjunto de índices del k -ésimo bloque. El estimador de CV del MSE es:

$$\text{CV}(K) = \frac{1}{n} \sum_{k=1}^K \sum_{i \in \mathcal{I}_k} \left(y_i - \hat{y}_i^{(-k)} \right)^2$$

donde $\hat{y}_i^{(-k)}$ es la predicción para la observación i obtenida entrenando el modelo con todos los datos excepto los del bloque k . El CV es un estimador casi insesgado del error de predicción esperado.

4.2.2 Elección de K : el trade-off sesgo-varianza en la partición

- **K pequeño (ej. $K = 5$):** cada modelo de entrenamiento usa solo el 80% de los datos. Sesgo algo mayor, pero varianza del estimador de CV menor porque las K evaluaciones son menos correlacionadas.
- **K grande (ej. $K = 10$ o **LOO**):** cada modelo entrena con casi todos los datos. Sesgo menor, pero mayor varianza del estimador. LOO (Leave-One-Out — Dejar Uno Afuera) es el caso $K = n$ y puede ser computacionalmente costoso.

En la práctica, $K = 5$ o $K = 10$ son elecciones estándar. Para el ejemplo de cobre, con $n \approx 300$ –500 muestras, $K = 10$ es razonable.

4.2.3 Dos usos distintos de la validación cruzada

Atención: dos usos distintos de CV

Uso 1 — Seleccionar λ dentro de LASSO: se usa CV para elegir el valor óptimo de λ , evaluando el MSE de LASSO para distintos λ sobre los mismos K bloques. Este es un paso de calibración interna del modelo.

Uso 2 — Comparar OLS con LASSO: una vez que LASSO tiene su λ óptimo (elegido por CV anidada o en un conjunto de validación separado), se evalúan OLS y LASSO en el mismo esquema de CV para comparar su MSE. Confundir estos dos usos puede llevar a una estimación optimista del error de LASSO.

4.2.4 ¿Cuándo la diferencia es significativa? Test de Diebold-Mariano

Obtener un MSE ligeramente menor para LASSO no es suficiente para concluir que es un modelo mejor. El **test de Diebold-Mariano** [2] permite testear formalmente si la diferencia en el error de predicción entre dos modelos es estadísticamente significativa.

En criollo: el test toma las diferencias en error de predicción observación por observación ($e_{1i}^2 - e_{2i}^2$) y pregunta si esas diferencias tienen media cero. Si el p -valor es chico, hay evidencia de que un modelo predice sistemáticamente mejor que el otro. Permite usar funciones de pérdida flexibles (no solo MSE) y tolera errores no gaussianos y correlacionados.

4.3 Tests formales: ¿por qué falla el LRT y cómo lo resolvemos?

4.3.1 El LRT clásico

Decimos que M_0 es **anidado** en M_1 ($M_0 \subset M_1$) cuando M_0 es un caso especial de M_1 obtenido imponiendo restricciones sobre sus parámetros. Por ejemplo, el modelo de regresión con solo SiO₂ y Fe₂O₃ está anidado en el modelo que incluye además Mo y profundidad: basta fijar los coeficientes de Mo y profundidad en cero para recuperar el modelo más simple. Esta relación de anidamiento es esencial para que el LRT tenga sentido.

La función $\ell(\hat{\theta})$ es la **log-verosimilitud maximizada**. Bajo normalidad de los errores, $\ell(\hat{\theta}) = -\frac{n}{2} \log(\hat{\sigma}^2) + \text{cte}$, donde $\hat{\sigma}^2 = \text{RSS}/n$ es la varianza residual estimada. Maximizar ℓ es equivalente a minimizar el RSS: los estimadores OLS y de máxima verosimilitud coinciden bajo normalidad. Cuanto mejor ajusta un modelo, mayor es su log-verosimilitud (menos negativa).

El test de razón de verosimilitud compara los modelos $M_0 \subset M_1$ usando el estadístico:

$$\Lambda = -2 \left[\ell(\hat{\theta}_0) - \ell(\hat{\theta}_1) \right] = n \log \left(\frac{\text{RSS}_0}{\text{RSS}_1} \right)$$

$\Lambda \geq 0$ siempre, porque el modelo más complejo (M_1) nunca puede tener mayor RSS que el más simple (M_0). Si Λ es grande, M_1 ajusta notablemente mejor y hay evidencia contra M_0 . Bajo condiciones de regularidad (Wilks, 1938), $\Lambda \sim \chi^2(q)$ bajo H_0 , donde $q = \dim(M_1) - \dim(M_0)$ es el número de restricciones impuestas. Esto permite calcular p -valores de forma directa.

4.3.2 Por qué falla el LRT con LASSO

OLS y LASSO no son modelos anidados en el sentido del LRT clásico. El parámetro λ no es un parámetro del modelo en el sentido usual: es un hiperparámetro de regularización. El estimador LASSO no se obtiene por máxima verosimilitud sino por un criterio penalizado. Esto tiene dos consecuencias:

- El estadístico Λ construido con la log-verosimilitud penalizada no tiene distribución χ^2 asintótica bajo ninguna hipótesis natural.
- La penalización L_1 introduce discontinuidades en el perfil de verosimilitud (los coeficientes saltan de cero a no-cero) que violan las condiciones de regularidad necesarias para los resultados de Wilks.

En criollo: no podemos usar la tabla χ^2 para evaluar si LASSO es “significativamente mejor” que OLS. Necesitamos construir la distribución del estadístico de comparación de otra manera.

4.3.3 Bootstrap paramétrico como solución

El bootstrap paramétrico permite construir la distribución nula del estadístico de comparación sin asumir ninguna forma distribucional asintótica.

```

ENTRADA: datos (X, y), estadístico T = MSE_OLS - MSE_LASSO
          observado, B iteraciones

PASO 1: Ajustar el modelo nulo M_0 (OLS) sobre los datos completos.
        Obtener residuos eps = y - X*beta_OLS y varianza s^2.

PASO 2: Para b = 1, ..., B:
    2a. Generar muestra bootstrap: y* = X*beta_OLS + eps*,
        donde eps* ~ N(0, s^2 * I)    [bootstrap parametrico]
    2b. Ajustar OLS y LASSO (con lambda elegido por CV interno)
        sobre (X, y*)
    2c. Calcular T* = MSE*_OLS - MSE*_LASSO (por CV en bootstrap)
    2d. Guardar T*[b]

PASO 3: p-valor = proporcion de T*[b] >= T observado

SALIDA: p-valor, distribucion empirica de T bajo H_0

```

La idea central es: si OLS fuera el modelo “verdadero”, ¿qué distribución tendría la diferencia de MSE entre ambos? El bootstrap lo simula generando datos desde OLS y midiendo cuántas veces LASSO “gana” por azar. Si en los datos reales LASSO gana por más de lo que ocurriría por azar, hay evidencia en su favor.

5. Síntesis: ¿cuándo usar cada herramienta?

5.1 Tabla resumen

Criterio	AIC / BIC	CV K -fold	Bootstrap
Pregunta	¿Qué modelo tiene mejor balance ajuste-complejidad?	¿Qué modelo predice mejor fuera de muestra?	¿La diferencia es significativa bajo el modelo nulo?
Supuestos	Distribución correctamente especificada; df efectivos válidos	Datos i.i.d. o estructura de dependencia conocida	Modelo nulo correctamente especificado
Costo computacional	Bajo (analítico)	Moderado (K ajustes por λ)	Alto ($B \times K$ ajustes)
Cuándo falla	df mal calculados; distribución mal especificada	n pequeño; datos dependientes sin corrección	Modelo nulo mal elegido; B insuficiente
Complementario con	Bootstrap (confirmar significancia)	AIC/BIC (verificar consistencia)	CV (validar la diferencia en error)

5.2 Diagrama de decisión




Figure 2: Diagrama de decisión para la selección de herramienta de comparación.

5.3 Aplicación al ejemplo de cobre

Aplicando las tres herramientas a los datos de cobre del USGS:

- **AIC/BIC:** LASSO con λ óptimo selecciona 7 variables y obtiene un AIC notablemente menor que OLS con 40 variables. BIC, más conservador, favorece un modelo aún más parsimonioso de

4 variables.

- **CV K -fold ($K = 10$):** el MSE de LASSO es un 18% menor que el de OLS en validación cruzada. La diferencia es consistente entre los 10 folds.
- **Bootstrap paramétrico ($B = 1000$):** el p -valor del test es 0,03, indicando que la mejora de LASSO difícilmente se explica por variabilidad muestral.

Las tres herramientas convergen en la misma conclusión: LASSO predice mejor la ley de cobre y la diferencia es estadísticamente significativa.

5.4 ¿Qué hacer cuando las tres herramientas no coinciden?

No siempre las tres herramientas apuntan en la misma dirección. Esta situación merece atención: no es un error, sino información adicional.

Escenario: AIC favorece LASSO pero CV no muestra diferencia

Posible interpretación: LASSO tiene menos parámetros efectivos (AIC lo premia) pero en este dataset particular la reducción de varianza no se traduce en mejor predicción fuera de muestra. Puede indicar que la multicolinealidad no es tan severa como parecía, o que el tamaño de muestra es insuficiente para que la diferencia sea detectable por CV.

Curso de acción: reportar ambos resultados, evaluar si n es suficiente, considerar aumentar K o usar LOO.

Escenario: CV favorece LASSO pero bootstrap no rechaza H_0

Posible interpretación: la mejora en CV es real pero pequeña en magnitud. El test bootstrap tiene baja potencia cuando la diferencia verdadera es chica. También puede indicar que el modelo nulo (OLS) está mal especificado.

Curso de acción: aumentar B , revisar el modelo nulo, considerar el tamaño del efecto (¿la diferencia en MSE es prácticamente relevante aunque no sea estadísticamente significativa?).

Escenario: las tres herramientas favorecen modelos distintos

Si AIC, CV y bootstrap señalan tres modelos diferentes, la señal en los datos es débil o la diferencia entre modelos es mínima en escala práctica.

Curso de acción: reportar todos los criterios, elegir por el objetivo científico (predicción $\rightarrow$ CV; parsimonia $\rightarrow$ BIC; inferencia formal $\rightarrow$ bootstrap), y plantear el caso como genuinamente indeterminado si la diferencia en MSE es pequeña en términos del problema aplicado.

Principio de convergencia de criterios

La convergencia de múltiples criterios es evidencia más sólida que cualquier criterio aislado. Cuando las tres herramientas coinciden, la conclusión es robusta. Cuando divergen, el desacuerdo es en sí mismo un resultado: indica que la elección del modelo depende del objetivo específico de análisis.

A. Proceso de ETL con la base de datos USGS

La National Geochemical Database del USGS contiene datos geoquímicos de más de 1,5 millones de muestras de roca, sedimento y suelo. Para construir el dataset de trabajo para esta clase, se recomienda el siguiente proceso de ETL (Extracción, Transformación y Carga — Extract, Transform,

Load).

A.1 Extracción

Los datos están disponibles en formato CSV y shapefile en:

<https://mrdata.usgs.gov/geochem/>

- Seleccionar muestras de tipo rock o sediment según el contexto geológico de interés.
- Filtrar por muestras con análisis de cobre (Cu) reportado.
- Descargar el CSV completo (puede superar los 500 MB; usar pandas con chunksize para lectura incremental).

A.2 Filtrado inicial

```

1 import pandas as pd
2 import numpy as np
3
4 # Lectura en chunks para archivos grandes
5 chunks = []
6 for chunk in pd.read_csv("usgs_geochem.csv", chunksize=50000,
7                           low_memory=False):
8     chunk = chunk[chunk["Cu"].notna()]
9     chunk = chunk[chunk["samp_type"].isin(["rock", "Rock"])]
10    chunks.append(chunk)
11
12 df = pd.concat(chunks, ignore_index=True)
13 print(f"Muestras con Cu: {len(df)}")

```

Listing 1: Lectura incremental y filtrado por Cu

A.3 Selección de variables geoquímicas

Seleccionar las variables con cobertura suficiente (al menos 60% de valores no nulos) y relevancia geológica para mineralización cuprífera:

```

1 OXIDOS = ["SiO2", "Al2O3", "Fe2O3", "MgO", "CaO",
2           "Na2O", "K2O", "TiO2", "MnO", "P2O5"]
3 TRAZA = ["Mo", "Pb", "Zn", "As", "Sb", "Bi", "Ag"]
4 GEO = ["depth", "lith_code"]
5 FEATURES = OXIDOS + TRAZA + GEO
6 TARGET = "Cu"
7
8 cobertura = df[FEATURES].notna().mean()
9 FEATURES_OK = cobertura[cobertura >= 0.60].index.tolist()
10 print(f"Variables retenidas: {len(FEATURES_OK)}")

```

Listing 2: Selección de variables con cobertura suficiente

A.4 Limpieza y tratamiento de valores faltantes

```

1 # 1. Eliminar filas sin Cu
2 df = df.dropna(subset=[TARGET])
3
4 # 2. Imputacion por mediana dentro de cada litologia
5 for col in FEATURES_OK:
6     df[col] = df.groupby("lith_code")[col].transform(
7         lambda x: x.fillna(x.median()))

```

```

8     df[col] = df[col].fillna(df[col].median())
9
10 # 3. Winsorizacion al 1%-99%
11 from scipy.stats import mstats
12 for col in FEATURES_OK + [TARGET]:
13     df[col] = mstats.winsorize(df[col], limits=[0.01, 0.01])
14
15 # 4. Transformacion logaritmica de variables sesgadas
16 SKEWED = ["Mo", "Pb", "Zn", "Cu"]
17 for col in SKEWED:
18     if col in df.columns:
19         df[col] = np.log1p(df[col]) # log(1+x) para manejar ceros

```

Listing 3: Imputación, winsorización y transformación logarítmica

A.5 Codificación y estandarización

```

1 from sklearn.preprocessing import StandardScaler
2 from sklearn.model_selection import train_test_split
3
4 # Codificacion one-hot de litologia
5 df = pd.get_dummies(df, columns=["lith_code"], drop_first=True)
6
7 # Train/test split estratificado por percentiles de Cu
8 df["Cu_bin"] = pd.qcut(df[TARGET], q=5, labels=False)
9 X_train, X_test, y_train, y_test = train_test_split(
10     df[FEATURES_FINAL], df[TARGET],
11     test_size=0.2, random_state=42,
12     stratify=df["Cu_bin"])
13
14 # Estandarizacion: OBLIGATORIA antes de LASSO
15 scaler = StandardScaler()
16 X_train_sc = scaler.fit_transform(X_train)
17 X_test_sc = scaler.transform(X_test) # fit solo en train

```

Listing 4: One-hot encoding, split estratificado y estandarización

Advertencia: data leakage en la estandarización

El scaler debe ajustarse (*fit*) solo sobre los datos de entrenamiento y luego aplicarse (*transform*) tanto al entrenamiento como al test. Ajustar el scaler sobre todos los datos constituye *data leakage* (fuga de información del conjunto de test hacia el modelo).

A.6 Verificación final

```

1 assert df[TARGET].isna().sum() == 0, "NaN en Cu"
2 assert df[FEATURES_FINAL].isna().sum().sum() == 0, "NaN en features"
3 print(f"Dimensiones finales: {X_train_sc.shape}")
4 print(f"Rango Cu (log): {y_train.min():.2f} - {y_train.max():.2f}")

```

Listing 5: Checklist de calidad del dataset

References

- [1] Akaike, H. (1974). A new look at the statistical model identification. *IEEE Transactions on Automatic Control*, 19(6), 716–723. <https://doi.org/10.1109/TAC.1974.1100705>
- [2] Diebold, F.X., & Mariano, R.S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–265. <https://doi.org/10.1080/07350015.1995.10524599>
- [3] Schwarz, G. (1978). Estimating the dimension of a model. *Annals of Statistics*, 6(2), 461–464. <https://doi.org/10.1214/aos/1176344136>
- [4] Tibshirani, R. (1996). Regression shrinkage and selection via the lasso. *Journal of the Royal Statistical Society: Series B*, 58(1), 267–288. <https://doi.org/10.1111/j.2517-6161.1996.tb02080.x>
- [5] Zou, H., Hastie, T., & Tibshirani, R. (2007). On the “degrees of freedom” of the lasso. *Annals of Statistics*, 35(5), 2173–2192. <https://doi.org/10.1214/009053607000000127>

Para lecturas adicionales: Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning* (2nd ed.). Springer.

Disponible en: <https://hastie.su.domains/ElemStatLearn/>